



PIS-IN AOI AI

智能质检项目建设方案

单机可运行 PoC · 数据一致性 · 三态决策 · Agent/RAG 治理闭环

项目版本 V3.5

建设周期 2024.09 - 2025.01 | 文档日期 2026.08

CONTENTS / SCOPE

目录与阅读口径

章节	主题	页码
01-03	建设背景、定位与核心功能	03-05
04-06	流程、数据流与技术架构	06-08
07-09	性能基准、AI 能力与系统集成	09-11
10-12	安全合规、团队与个人贡献	12-14
13-16	路线图、成本、亮点与指标	15-18
17	结论与生产门禁	19

事实边界

本方案以仓库代码、V3.5 技术文档、部署手册与测试证据为依据。当前交付定位是可运行单机 PoC + 数据适配与生产门禁基线；真实图像、标注集、YOLO 权重、TensorRT Engine、连续生产样本与正式等保测评尚不在仓库中。文中“目标值”“建议值”“待验收”均不表述为生产实绩。

01 / BACKGROUND

建设背景与项目定位

11组	3态	8页	单机
候选光源输入	PASS/FAIL/REVIEW	质量运营界面	工控机部署

业务痛点

- 多光源 2D、3D 量测与原 AOI 结果分散，乱序、重复、重启归零时难以证明同属一个物理器件。
- 仅输出 PASS/FAIL 无法承载低置信度、输入缺失和身份冲突，容易造成静默漏放或错误放行。
- 缺陷、Tray/Slot、人工复核、工站预警与异常报告缺少统一追溯链。
- 模型效果、版本发布和回滚缺少可审计证据；Agent 若进入实时判定会放大不确定性风险。

建设目标

事件统一

Source Key
附件汇聚
全链路追溯

AI 复判

YOLOv8
3D 后融合
三态护栏

质量闭环

人工复核
预警报表
模型治理

02 / BUILD VS BUY

自建与采购决策

维度	通用采购方案	项目自建方案	结论
设备/数据适配	标准协议覆盖较好，PIS-IN 多文件语义需定制	Source Adapter + Source Key 精确贴合本机数据	核心自建
AI 推理	可采购标注、训练与 GPU 工具链	YOLOv8/TensorRT 适配、3D 规则与三态策略自建	混合
质量运营	通用 QMS/MES 能承接结果	Tray Map、复核、告警、DRAFT 报告需业务化	核心自建
基础设施	数据库、GPU、NAS、监控可成熟采购	Compose 编排与故障隔离自建	优先采购成熟组件
总成本/锁定	上线快但定制与授权成本较高	初期研发投入高，规则/数据/模型可控	PoC 适合自建

项目定位

不是替换 PIS-IN AOI 的机械与基础检测能力，而是在其输出之上建设可追溯的 AI 辅助复判与质量运营闭环。当前由操作员或本机 AOI 软件触发，不依赖自动化 Handler；MES 仅作为可选异步接收方。

03 / FUNCTION MAP

核心功能全景



前端业务页面

生产总览、实时检测、Tray Map、人工复核、缺陷报表、预警与异常报告、模型治理、项目说明，共 8 个页面。

04 / BUSINESS FLOW

业务流程与责任边界



结果	进入条件	后续动作
PASS	输入完整且正常置信度达到审批阈值	记录模型/策略/输入指纹；仅受控模式允许自动放行
FAIL	3D 硬规则超限或明确缺陷证据达到门槛	缺陷归类、Tray 定位、工站窗口统计
REVIEW	低置信、未知类别、模型不可用或关键输入缺失	进入人工复核，不允许静默转 PASS
QUARANTINED	身份缺失、冲突或附件归属不可证明	持久化隔离并人工归属

05 / DATA FLOW

数据流向与一致性设计



核心一致性约束

- Source Key = DeviceID + DeviceSessionID + InspectionSequence + TrayID + SlotIndex + Surface; 光源是附件属性，不进入主键。
- 数据库唯一约束承担最终幂等；推理结果按事件、模型版本、策略版本和输入指纹共存。
- 不使用邻近时间戳或文件顺序猜测归属；无法证明身份的数据进入 quarantine_events。
- Agent 只读取审计事实和知识证据，不修改事件身份，也不创建自动 PASS。

关键数据表

inspection_events、data_attachment_links、inference_results、review_records、quarantine_events、station_alerts、anomaly_reports。

技术架构

层级	核心组件	职责与设计选择
展示层	React 18 / TypeScript / Vite / ECharts / Nginx	8 个质量运营页面；Nginx 代理 API 与 SPA fallback
核心应用	FastAPI / Pydantic / SQLAlchemy 2 / Alembic	模块化单体承载确定性实时链路，降低单机排障复杂度
推理层	YOLOv8s / ONNX / TensorRT / 3D 规则	可替换 adapter；异常 fail-closed 到 REVIEW
数据层	PostgreSQL 14+（目标 16） / pgvector；测试用 SQLite	事务幂等、版本共存、审计与向量检索
治理层	数据质量/报告/模型治理 Agent	独立进程，超时不影响检测主链路
部署层	Docker Compose / GPU overlay / healthcheck	单工控机容器化、服务可独立重启

架构判断

当前是单机容器化模块服务架构，不是全微服务。确定性检测主链路保持紧凑；非实时 Agent/RAG 独立隔离，以获得低延迟、易回滚和可维护性的平衡。

核心组件与性能基准

指标	当前证据	阶段目标/验收方式
软件正确性	API 63、Agent/RAG 6、Simulator 2 条历史通过记录	发布前重新执行全套单测、前端 build/typecheck、E2E
演示数据	24 条确定性事件；PASS/FAIL/REVIEW = 16/4/4	仅证明流程可复现，不代表生产分布；验收门槛为 ≥1000 事件 + 故障注入（详见数据一致性专章）
推理延迟 P95	仓库无真实权重与目标工控机实测	在目标 GPU 上按模型/产品/光源组合分桶压测
持续吞吐	尚无连续生产样本	记录稳态 FPS、队列深度、GPU/CPU/内存与磁盘水位
质量效果	误报率为阶段目标，非实绩	独立盲测同时报告关键缺陷漏放、REVIEW 与置信区间
静默错配	设计目标 0	乱序/重复/重启/延迟/断网故障注入验证

建议算力基线（由需求推导，待现场实测定稿）

侧别	配置	选型依据（由需求推导）	状态
训练侧	2 × L40S 48GB	中心侧机房资源；按训练吞吐与 TensorRT 引擎编译并行度估算，非本机部署	待实测
边缘推理侧（单体设备 · PoC 节点）	2 × RTX 4000 Ada 20GB	本机旁路复判；按“相机路数 × 模型 FPS”估算，单卡已够，2 卡为并发/冗余预留；仓库暂无真实权重实测	待实测
治理侧	1 × L4 24GB	离线检索/报告/门禁；若 LLM/RAG 走外部 API，本地可不配	待实测
存储	容量 40–80TB NAS	容量 = 事件率 × 单事件图像体积 × 保留周期；NAS 为顺序写，需关注带宽/IOPS 而非仅容量	待实测

选型说明（需求推导口径）：“单机”指单体设备——即部署在检测工位的一台独立工控机/边缘设备，仅承载本表“边缘推理侧（2 × RTX 4000 Ada）”的本机旁路复判；训练侧（2 × L40S）与治理侧（1 × L4）为独立于该单体设备的中心侧资源，不与其混装，请勿理解为“全部模块运行于同一台机器”。

存储容量推导（示例，非承诺）：容量 ≈ 事件率 × 单事件图像体积 × 保留周期。例：4 路相机 × 约 6MB/图 × 约 3 图/事件 × 600 事件/班次 × 3 班次/日 × 90 天留存 ≈ 数十 TB，故给出 40–80TB 区间；实际以现场事件率与留存策略为准。

待实测与缺口：算力为凭经验初列、尚未经目标工控机实测，且与第 9 页阶段目标（P95 时延、稳态 FPS、队列深度、GPU 水位）尚未闭环映射；PoC 为非 HA 部署，生产需补充供电/散热冗余与机架规划。GPU-free 模式可完成确定性演示与接口联调。

08 / AI CAPABILITIES

AI 核心能力

能力	实现方式	安全边界
视觉检测	YOLOv8s 基线，ONNX → TensorRT FP16，结合 3D 后融合	真实权重/Engine 缺失时不声明精度，运行异常转 REVIEW
数据质量 Agent	汇总身份、附件、时间偏差、重复与缺失风险	不修改身份、不自动放行
复核与报告 Agent	检索 SOP/历史案例，生成带引用的 DRAFT	不自动确认根因、不批准报告
模型治理 Agent	汇总召回、漏放、P95、漂移、影子差异与回滚证据	不直接发布模型
RAG	PostgreSQL + pgvector；缺陷字典、SOP、手册、历史异常、发布说明	证据可引用；超时降级为人工补充

关键设计原则

视觉模型负责生成证据，规则负责质量边界，Agent 负责检索、汇总与解释，人负责最终确认和高风险审批。实时确定性链路与非确定性治理链路分离。

09 / INTEGRATION

外部系统集成方案

系统	当前状态	集成方式	故障策略
PIS-IN AOI	当前主链路	本机 Source Adapter 读取设备导出/采集结果，稳定性与 Hash 校验	输入不完整进入 REVIEW/隔离
MES	可选规划	异步 Outbox、幂等消息、重试与补偿；只接收结果/证据索引	MES 不可用不阻塞本机检测
自动化 Handler	默认关闭	保留 TCP/SESSION_SYNC/BIN 设计资产；未来独立立项联调	HANDLER_INTEGRATION_ENABLED=false
企业通知/QMS	待需求确认	通过告警 Webhook/消息适配器输出 ACK、报告状态与链接	不把通知成功作为质量判定条件
SAP/Workday/钉钉/企微	不在当前范围	若后续存在工单、人员或通知需求，再按 API/消息总线接入	不虚构现有集成

集成原则

- 实时判定不依赖企业外围系统；所有外部调用均需超时、幂等、重试和可补偿。
- 外部系统只消费受控数据视图，避免直接访问工控机数据库或原始图像目录。
- 所有接口记录 correlation_id、event_uuid、版本与结果状态，支持审计和重放。

10 / SECURITY & COMPLIANCE

安全合规方案

控制域	当前/建议措施	等保三级对齐说明
边界防护	工控机/生产网分区；Nginx 单入口；Agent 与数据库仅内网暴露	对应安全区域边界与访问控制，需现场网络策略佐证
身份权限	建议接入企业 SSO/RBAC；复核、报告批准、模型发布职责分离	当前仓库未实现完整 IAM，列为上线门禁
数据安全	传输 TLS、磁盘/备份加密、最小化采集、日志脱敏、保留期策略	按数据分类分级与个人信息最小化执行
审计追溯	event_uuid、输入指纹、model/policy_version、reviewer、报告与 Agent 引用	满足关键操作留痕与责任追踪
主机/应用	镜像扫描、依赖治理、最小权限容器、补丁基线、密钥外置	生产不得使用示例口令
韧性恢复	健康检查、备份恢复、模型回滚、断电重启与故障注入演练	形成制度、记录并接受测评

合规结论

本项目具备对齐等保三级的技术设计基础，但尚不能宣称已通过等保三级。正式结论需要定级备案、差距整改、第三方测评和持续运营证据。

11 / TEAM

团队配置与分工

角色	人数	核心职责	主要交付
产品/AI 负责人	1	业务拆解、架构、指标门禁、跨团队推进	方案、路线图、验收口径
后端工程师	2	API、领域模型、数据一致性、告警与集成	FastAPI、SQLAlchemy、Alembic
前端工程师	1	质量运营界面与交互	React 8 页、ECharts、E2E
算法工程师	2	数据、YOLO、TensorRT、3D 融合、阈值校准	模型/Engine、盲测报告
测试工程师	1	功能、异常、性能与回归	测试矩阵、故障注入
实施运维	1	设备适配、部署、监控、备份与培训	Compose、Runbook、现场验收

协作机制

以事件数据契约、模型/策略版本、上线门禁和可复现测试作为跨角色共同语言。团队共 8 人，按阶段投入，不代表全周期均满负荷。

12 / PERSONAL OWNERSHIP

个人核心贡献

贡献方向	具体工作	形成的能力证据
需求与指标	将误报、漏放、REVIEW、P95、吞吐、错配率拆成阶段门禁	把模糊 AI 需求转为可测试、可验收指标
工业数据建模	设计 Source Key、附件汇聚、状态机、quarantine 与版本共存	解决乱序、重复、重启归零与身份缺失
推理工程化	推动 YOLOv8/TensorRT adapter、3D 后融合与三态决策	不把模型输出直接等同生产放行
Agent/RAG 架构	规划 3 Agent、证据引用、超时降级与发布 BLOCK	让非确定性能力受控、可解释、可隔离
全链路交付	协调 API、前端、测试、Compose、手册与项目展示	从方案到可运行 PoC 的跨团队推进
事实治理	明确已测试、目标值和待现场验证项	避免把演示数据包装为生产实绩

个人价值总结

核心价值不是单点训练一个模型，而是把工业现场的数据一致性、视觉证据、规则护栏、人工复核、质量运营和模型治理组织成可运行、可审计、可逐步上线的系统。

13 / ROADMAP

实施路线图

阶段	周期建议	关键任务	里程碑/退出条件
1. 设计评审	2 周	现场调研、接口/字段、缺陷字典、验收口径	数据契约与门禁签字
2. PoC 基线	4-6 周	Source Adapter、事件模型、Demo 推理、8 页运营界面	单机流程可运行、异常可追溯
3. 真实数据联调	4-6 周	标注、训练、TensorRT、3D 融合、故障注入	独立盲测、P95/吞吐达标
4. 影子运行	4 周+	新旧结果共存、人工复核、阈值校准、回滚演练	静默错配 0、差异可解释
5. 受控上线	分批推进	质量审批、小范围 AUTO_PASS、持续监控与复盘	阶段目标达标后逐步扩围

关键里程碑



14 / COST & ROI

成本估算与投资分析

成本项	估算（万元）	口径与主要假设
人员研发	300	8 人按阶段投入；产品/AI、后端、前端、算法、测试、实施
训练/边缘 GPU 与 NAS	90	2×L40S、2 台边缘 GPU 工控机、L4、40-80TB 存储的参考配置
数据采集与标注治理	45	现场样本、标注复核、缺陷字典与金标准
集成测试与实施	35	设备适配、网络、盲测、培训与上线支持
安全合规与运维工具	15	扫描、监控、备份、日志与等保差距整改预留
风险准备金	15	约 3%，覆盖接口变化和现场不可预见项
内部预算口径	500	项目文档中的内部估算；需按采购询价和人月重新核算

投资回报口径

建议以“减少 NG 候选人工复判工时 + 降低漏放/客诉损失 + 缩短异常定位时间 + 提高设备/批次追溯效率”建立年度收益模型。由于仓库无真实产量、人工时薪、客诉损失和停线成本，本方案不虚构 ROI 数值；正式立项应以 12 个月 TCO、回收期 and 敏感性分析决策。

15 / HIGHLIGHTS

项目亮点

身份先于推理

Source Key
数据库幂等
隔离未知归属

三态安全决策

缺失不放行
低置信复核
规则优先

多模态证据链

多光源 2D
3D / 原 AOI
Tray/Slot

Agent 故障隔离

异步治理
带证据引用
超时可降级

单机可部署

Compose
无 GPU 演示
GPU overlay

诚实的生产门禁

目标≠实绩
影子运行
可回滚

差异化价值

项目把 AI 精度问题上升为一套工业质量系统问题：先保证数据身份正确，再生成模型证据，以规则和人在回路控制风险，最后用 Agent/RAG 提升治理效率。

16 / KPI DASHBOARD

核心指标总览

12%	≤6%	≤3%	≤1.5%
NG候选误报基线	PoC目标	受控上线目标	成熟目标

指标域	核心指标	口径/目标
质量	关键缺陷召回、自动 PASS 漏放、NG 候选误报、全检误报	全检误报目标 ≤0.5%；其余按缺陷/产品分桶
安全	静默错配、关键输入缺失自动 PASS、越权发布	目标均为 0
效率	端到端 P95、持续吞吐、REVIEW 比例、人工复核时长	目标工控机与连续样本实测
稳定性	服务可用性、队列积压、恢复时间、备份恢复成功率	影子与受控阶段设 SLO
治理	报告引用命中、Agent 拒答/降级、模型回滚耗时	不得影响实时检测主链路
交付	测试通过、部署成功、故障注入、培训与文档	作为阶段退出条件

指标解释

误报阶段目标只针对 AOI NG 候选池；必须同时报告全检件分母、关键缺陷漏放、REVIEW 比例与置信区间，避免单一指标优化掩盖风险。

17 / CONCLUSION

结论与上线门禁

当前结论

V3.5 已形成单机可运行 PoC、数据适配与部署基线：覆盖多源事件关联、三态决策、人工复核、质量运营、3 Agent/RAG、容器化部署与故障隔离。它可用于方案评审、演示、接口联调和现场验证，但不等同于生产自动 PASS 批准。

生产前必须完成

- 确认真实 PIS-IN 身份字段、光源集合和文件落盘行为，接入真实图像、标注集、YOLO 权重与 TensorRT Engine。
- 完成按 Tray/批次/设备隔离的独立盲测，验证关键缺陷召回、漏放、误报、REVIEW、端到端 P95 和持续吞吐。
- 通过乱序、重复、延迟、断网、磁盘满、断电重启、模型不可用等故障注入，证明静默错配和异常自动 PASS 为 0。
- 完成模型回滚、数据库恢复、权限审计、日志监控、现场培训与质量/设备/工艺联合审批。
- 需要等保三级时，完成定级备案、差距整改、第三方测评与持续运营证据闭环。

让每一次 AI 判定都能被追溯、复核、解释和治理。